Identificação Adaptativa de Covariâncias de Ruído em Filtros de Kalman

Sistemas Inteligentes – Atividade 02

Mateus Pincho de Oliveira

Universidade Federal de Campina Grande (UFCG)
Centro de Engenharia Elétrica e Informática (CEEI)

Abril de 2026

O Filtro de Kalman Precisa de Q e R

Sistema Linear em Tempo Discreto

$$\mathbf{x}(k+1) = F\,\mathbf{x}(k) + \Gamma\,\mathbf{v}(k), \qquad \mathbf{v}(k) \sim \mathcal{N}(\mathbf{0},\, Q)$$

$$\mathbf{z}(k) = H\,\mathbf{x}(k) + \mathbf{w}(k), \qquad \mathbf{w}(k) \sim \mathcal{N}(\mathbf{0},\, R)$$

Q **e** R **determinam:**

- A covariância de predição $P(k{+}1|k)$
- A covariância da inovação $S = HPH' + R$
- O ganho de Kalman $W = PH'S^{-1}$

O problema prático

Em aplicações reais, Q e R **não são conhecidos a priori**. Escolhas erradas degradam o filtro.

Por Que Q e R Incorretos São Problemáticos?

Q muito grande

O filtro acredita que a dinâmica é muito imprevisível

- Confia demais nas medições
- Estimativas ruidosas

Q muito pequeno

O filtro é excessivamente confiante na predição

- Ignora informações úteis das medições
- Estimativas lentas e enviesadas

Um problema com 50 anos

Desde Mehra (1970), pesquisadores buscam estimar Q e R **diretamente dos dados**.

Zhang et al. (2020) propõem uma solução iterativa baseada em 6 passos, mais precisa que métodos anteriores.

Objetivo: dado $\{\mathbf{z}(1), \ldots, \mathbf{z}(N)\}$, identificar Q e R.

Por Que Analisar a Inovação?

Inovação (resíduo de predição)

$$\boldsymbol{\nu}(k) = \mathbf{z}(k) - H\,\hat{\mathbf{x}}(k|k-1)$$

Diferença entre a medição recebida e a medição **predita**.

Ela é a única grandeza calculável que carrega informações sobre Q e R ao mesmo tempo.

Propriedade fundamental:
Para um filtro ótimo, $\{\boldsymbol{\nu}(k)\}$ deve ser **ruído branco** (amostras não correlacionadas).

$$\mathbb{E}[\boldsymbol{\nu}(k)\,\boldsymbol{\nu}(k-i)'] = \begin{cases} S & i = 0 \\ 0 & i \geq 1 \end{cases}$$

Ideia central

As autocovariâncias amostrais $\hat{C}(i)$ são funções de Q e R. Inverta essa relação para identificar Q e R a partir dos dados.

Visão Geral: Algoritmo de Seis Passos

1. **Passar o filtro de Kalman** com ganho constante $W^{(r)}$; coletar $\{\boldsymbol{\nu}(k)\}$ e resíduos pós-ajuste $\{\boldsymbol{\mu}(k)\}$
2. **Calcular autocovariâncias amostrais** $\hat{C}(i)$, $i = 0, 1, \ldots, M-1$
3. **Atualizar** W via descida de gradiente sobre o objetivo de brancura J
4. **Estimar** R pela fórmula R3 (garante definição positiva)
5. **Estimar** Q **e** P via iteração de Lyapunov com restrições estruturais
6. **Loop externo:** re-inicializar $W^{(0)}$ e repetir até convergência (≤ 20 iterações)

Resultado

Ao convergir, o algoritmo entrega estimativas $\hat{Q}$, $\hat{R}$, $\hat{W}$, $\hat{S}$ e $\bar{P}$ otimizadas pelos dados.

Passos 1–2: Filtro de Kalman e Autocovariâncias

Passo 1 — Filtro com ganho constante W:

$$\hat{\mathbf{x}}(k{+}1|k) = F\,\hat{\mathbf{x}}(k|k), \qquad \boldsymbol{\nu}(k{+}1) = \mathbf{z}(k{+}1) - H\,\hat{\mathbf{x}}(k{+}1|k)$$

$$\hat{\mathbf{x}}(k{+}1|k{+}1) = \hat{\mathbf{x}}(k{+}1|k) + W\,\boldsymbol{\nu}(k{+}1), \qquad \boldsymbol{\mu}(k{+}1) = \mathbf{z}(k{+}1) - H\,\hat{\mathbf{x}}(k{+}1|k{+}1)$$

Passo 2 — Autocovariância amostral (eq. 50):

$$\hat{C}(i) = \frac{1}{N-M}\sum_{j=1}^{N-M} \boldsymbol{\nu}(j)\,\boldsymbol{\nu}(j{+}i)', \qquad i = 0, 1, \ldots, M{-}1$$

Parâmetro M (número de atrasos)

M controla o compromisso entre variância e resolução temporal. Deve satisfazer $M \geq n_x$; tipicamente $M \in [40, 100]$.

Passo 3: Atualização do Ganho W por Descida de Gradiente

Objetivo de brancura (eq. 52):

$$J = \frac{1}{2}\,\mathrm{tr}\left\{ \sum_{i=1}^{M-1} \left[\mathrm{diag}(\hat{C}(0))\right]^{-1/2} \hat{C}(i)' \left[\mathrm{diag}(\hat{C}(0))\right]^{-1} \hat{C}(i) \left[\mathrm{diag}(\hat{C}(0))\right]^{-1/2} \right\}$$

$J = 0$ significa inovações perfeitamente brancas $\Rightarrow$ filtro ótimo.

Tamanho de passo adaptativo (Bold Driver, eq. 137):

$$\alpha^{(r)} = \begin{cases} 0{,}5\ \alpha^{(r-1)} & \text{se } J^{(r)} > J^{(r-1)} \quad \text{(passo muito grande)} \\ \min\!\left(1{,}1\ \alpha^{(r-1)},\ \bar{c}\right) & \text{caso contrário} \quad \text{(passo aumenta 10\%)} \end{cases}$$

Critérios de parada

$\delta_W < 10^{-6}$ | $\|\nabla_W J\| < 10^{-6}$ | $J < 10^{-6}$ | 5 iterações sem melhora | n_L iterações máximas

Passo 4: Estimação de R (Fórmula R3)

Resíduo pós-ajuste: $\boldsymbol{\mu}(k) = (I - HW)\,\boldsymbol{\nu}(k) \quad \Rightarrow \quad$ covariância amostral: $\hat{G} = \frac{1}{N}\sum_k \boldsymbol{\mu}(k)\boldsymbol{\mu}(k)'$

Fórmula R3 — equação de Riccati contínua (eq. 78):

$$\hat{G} = R\,S^{-1}\,R \qquad \text{com } S = \hat{C}(0)$$

Solução numérica (Apêndice F):

1. Cholesky: $S^{-1} = LL'$
2. Eigendecomposição: $L'\hat{G}L = U\Lambda U'$
3. Raiz quadrada: $L'RL = U\Lambda^{1/2}U'$
4. Recuperar: $R = (L')^{-1}U\Lambda^{1/2}U'L^{-1}$

Por que R3?

Garante $\hat{R}$ **definida positiva** por construção — as outras fórmulas podem produzir autovalores negativos devido a erros numéricos.

Passos 5–6: Estimação de Q/P e Laço Externo

Passo 5 — Iteração dupla (Lyapunov):

Inicialização: $\Gamma Q^{(0)}\Gamma' = WSW'$ (aproximação de processo de Wiener)
Laço interno (fixado $Q^{(t)}$, iterando em P):

$$P^{(\ell+1)} = \left[\left(FP^{(\ell)}F' + \Gamma Q^{(t)}\Gamma'\right)^{-1} + H'R^{-1}H\right]^{-1}$$

Atualização de Q:

$$D^{(t+1)} = P + WSW' - FPF', \qquad Q^{(t+1)} = \Gamma^{\dagger}\, D^{(t+1)}\, (\Gamma')^{\dagger}$$

Passo 6 — Laço externo (aproximação sucessiva):

- Com $(\hat{Q}, \hat{R})$ atualizados, resolver DARE para novo $W^{(0)}$
- Repetir Passos 1–5 (até 20 iterações externas)
- Guardar a melhor solução (W^*, J^*) ao longo de todas as iterações

Caso 1 — Descrição do Sistema Cinemático

Modelo de velocidade constante:

$$F = \begin{bmatrix} 1 & T \\ 0 & 1 \end{bmatrix}, \quad H = \begin{bmatrix} 1 & 0 \end{bmatrix}, \quad \Gamma = \begin{bmatrix} T^2/2 \\ T \end{bmatrix}$$

com $T = 0{,}1\,\mathrm{s}$ (período de amostragem).

Valores verdadeiros:

$$Q_{\text{true}} = 0{,}0025, \quad R_{\text{true}} = 0{,}01$$

Configuração Monte Carlo

- $N = 1000$ amostras por realização
- 100 realizações Monte Carlo
- $M \in \{10, 20, 30, 40, 50, 100\}$
- Ganho inicial via DARE com $Q_0 = R_0 = 0{,}1$

Métricas reportadas:
média, IC 95% e RMSE de $\hat{R}$, $\hat{Q}$, $\hat{W}$, $\hat{P}$ em cada valor de M.

Caso 1 — O Que o Artigo Afirma

Afirmações teóricas de Zhang et al. (2020)

- O algoritmo converge para os valores verdadeiros quando $N \to \infty$
- Aumentar M melhora a estimação de Q (mais informação de atraso)
- Existe um M ótimo que equilibra variância e viés amostral
- As estimativas devem ser **não enviesadas**: a média das realizações converge para o valor verdadeiro

Métrica principal — RMSE:

$$\mathrm{RMSE}(\hat{\theta}) = \sqrt{\frac{1}{N_{\mathrm{MC}}} \sum_{i=1}^{N_{\mathrm{MC}}} \left(\hat{\theta}^{(i)} - \theta_{\mathrm{true}}\right)^2}$$

Objetivo

Reproduzir e validar esses resultados via simulação, comparando com os valores da Tabela 3 do artigo.

Caso 1 — RMSE em Função do Número de Atrasos M

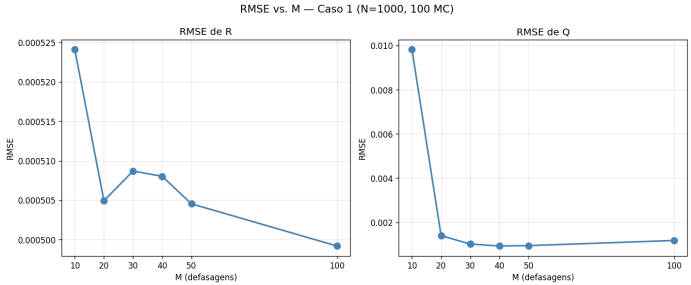

Figura 1: RMSE de $\hat{Q}$ e $\hat{R}$ sobre 100 realizações Monte Carlo, $M \in \{10, 20, 30, 40, 50, 100\}$.

Melhor resultado ($M = 40$)

$$\text{RMSE}(\hat{R}) = 5{,}1 \times 10^{-4}$$
$$\text{RMSE}(\hat{Q}) = 9{,}3 \times 10^{-4}$$

Observação: o RMSE de $\hat{Q}$ decresce com M até $M = 40$, depois estabiliza (efeito de janelamento).

$\hat{R}$ é pouco sensível a M — estimativa robusta ao número de atrasos.

Caso 1 — Distribuição Monte Carlo das Estimativas

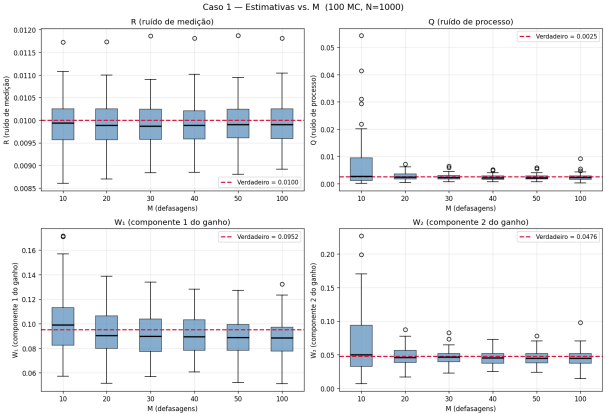

Figura 2: Distribuição de $\hat{Q}$ e $\hat{R}$ para cada valor de M. Linha tracejada: valor verdadeiro.

Resultados ($M = 40$)

	$\hat{R}$	$\hat{Q}$
Verdadeiro	0,010	0,0025
Média	0,00993	0,00229
IC 2,5%	0,00909	0,00084
IC 97,5%	0,01091	0,00391

Valor verdadeiro **dentro** do IC 95% em todas as realizações ✓

NIS — O Que é e Como Usar

NIS — Normalized Innovation Squared (eq. 191)

$$\varepsilon(k) = \boldsymbol{\nu}(k)' \, S^{-1} \, \boldsymbol{\nu}(k)$$

Mede o quanto a inovação é "surpreendente" dado o tamanho esperado da covariância da inovação S.

Propriedade teórica: Para um filtro **bem calibrado** (com os Q e R corretos):

$$\varepsilon(k) \sim \chi^2(n_z), \qquad \mathbb{E}[\varepsilon(k)] = n_z$$

Plotamos $\varepsilon(k)/n_z$ — valor esperado igual a 1.

Interpretação

- NIS $\gg 1$: filtro subestima a incerteza (Q ou R pequenos demais)
- NIS $\ll 1$: filtro superestima a incerteza (Q ou R grandes demais)
- NIS ≈ 1: filtro **consistente** ✓

Caso 1 — Consistência pelo Teste NIS

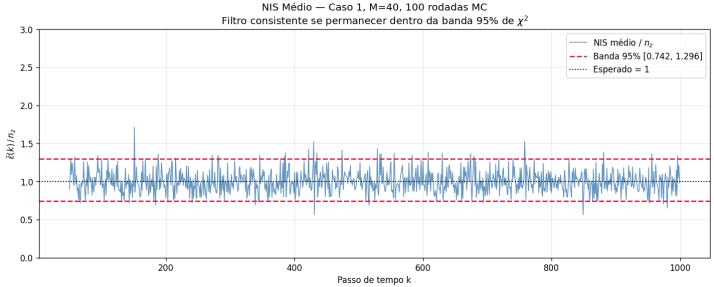

Figura 3: NIS ao longo do tempo para o Caso 1 ($M = 40$, média sobre 100 realizações). Faixa sombreada: intervalo 95% da $\chi^2(1)$.

Diagnóstico

- NIS médio $\approx 1{,}0$
- Fração dentro da banda 95%: alta ✓
- Sem tendência sistemática

O filtro com as covariâncias estimadas pelo algoritmo de 6 passos é **estatisticamente consistente**.

Aplicação EKF — Modelo do Sistema

Modelo PVA (posição-velocidade-aceleração):

$$\mathbf{x} = [p_x,\ \dot{p}_x,\ \ddot{p}_x,\ p_y,\ \dot{p}_y,\ \ddot{p}_y]^\top \in \mathbb{R}^6$$

Medição não linear (distâncias):

$$z_i(k) = \sqrt{(p_x - a_{xi})^2 + (p_y - a_{yi})^2} + v_i$$

4 estações base: S_1=(0, 0), S_2=(600, 600), S_3=(0, 600), S_4=(600, 0) (metros)

Parâmetros

Período T_s	1,0 s
N	100 passos
σ_R	1,0 m (ruído sensor)
S_a	0,01 m^2/s^3 (Singer)
$R = \sigma^2 I_4$	$= I_4$

Por que EKF?

A medição é **não linear**. O Jacobiano H_k é recalculado a cada passo na estimativa a priori $\hat{\mathbf{x}}(k|k-1)$.

EKF — Trajetória Quadrada

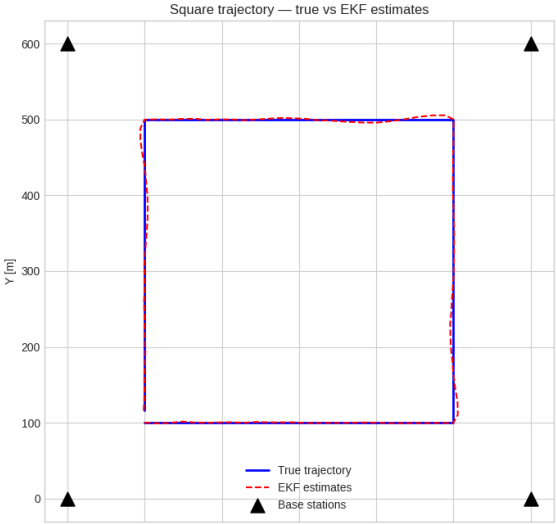

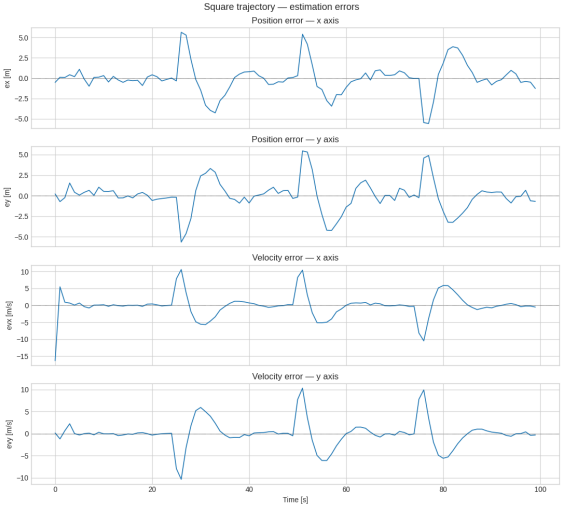

EKF — Trajetória Circular

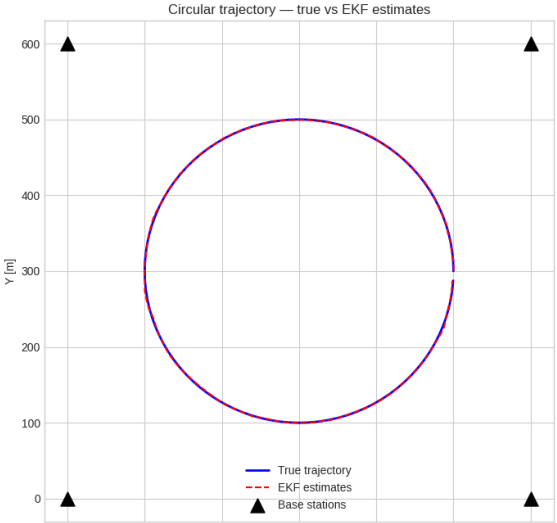

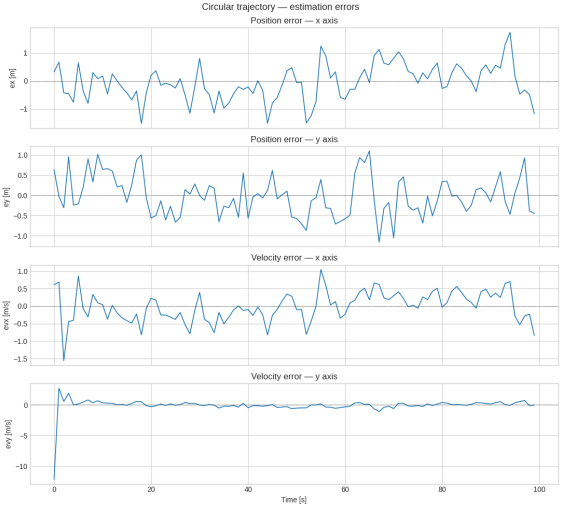

EKF — Validação pelo Teste NIS

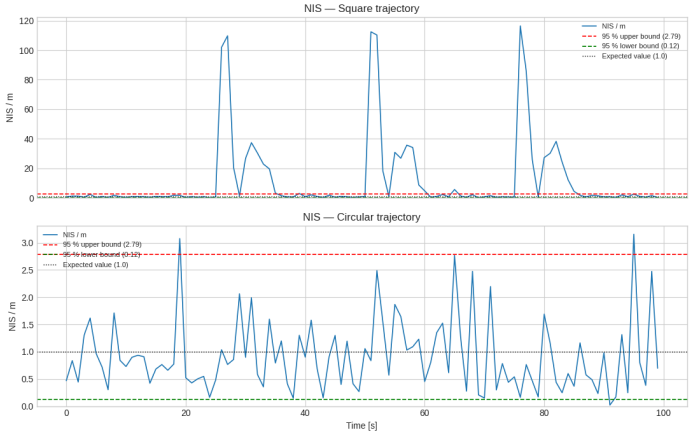

Figura 8: NIS normalizado para as duas trajetórias. Linhas tracejadas: limites 95% da $\chi^2(4)/4$.

Resultados NIS

Trajetória	Dentro da banda 95%
Quadrada	75%
Circular	84%

Interpretação: desempenho aceitável, considerando a linearização aproximada do EKF e o descasamento do modelo nos cantos da trajetória quadrada.

Conclusões

Algoritmo de Seis Passos

O método de Zhang et al. (2020) estima Q e R com RMSE baixo sem qualquer conhecimento a priori dos valores reais. Melhor resultado para $M = 40$ ($N = 1000$): RMSE($\hat{R}$) $= 5{,}1 \times 10^{-4}$, RMSE($\hat{Q}$) $= 9{,}3 \times 10^{-4}$.

Sensibilidade ao Parâmetro M

$M = 40$ é o ponto ótimo para este cenário ($N = 1000$): valores maiores não melhoram significativamente a estimação.

Aplicação com EKF

Rastreamento 2D com medições de distância não lineares: RMSE de posição $\approx 0{,}4$ m, NIS dentro da faixa 75–84% (ligeiro descasamento esperado pela linearização do EKF).

Referência: Zhang et al. (2020), *IEEE Access*, vol. 8, pp. 59362–59388.

Obrigado!

Mateus Pincho de Oliveira

Universidade Federal de Campina Grande – UFCG

Sistemas Inteligentes – 2026